Desarrollo de un pipeline ETL para la estimación de biomasa residual agrícola a escala departamental en Argentina

Proyecto OPTIMIA-HV — Informe de avance de tesis

Autor	Marco Ferro
Institución	Universidad Nacional de Villa Mercedes (UNVM)
Carrera	Ingeniería en Sistemas de Información
Proyecto / Tesis	OPTIMIA-HV
Tipo de documento	Informe de avance de proyecto

Resumen

En el marco de mi tesis OPTIMIA-HV desarrollé un sistema de extracción, transformación, carga y visualización orientado a estimar la biomasa residual generada por cultivos extensivos en Argentina a granularidad departamental. El trabajo comprende: (i) extractores HTTP contra portales oficiales, incluyendo la superación de protecciones Cloudflare mediante *browser impersonation*; (ii) un pipeline de transformación con normalización léxica y geográfica, taxonomía de cultivos, reconciliación multi-fuente y cálculo de residuo a partir del índice de cosecha; (iii) contenedorización con Docker Compose (worker ETL, scheduler Ofelia y dashboard Streamlit); y (iv) persistencia auditable en Parquet.

Descarté la serie de la Bolsa de Cereales de Buenos Aires porque utiliza zonas PAS, incompatibles con la clave provincia–departamento. Sobre el conjunto válido obtuve cobertura de **23 provincias**, **411 departamentos** y **17 cultivos con índice de cosecha documentado**, reteniendo el **82,22 %** de los registros y el **87,59 %** de la producción declarada, que concentran el **97,53 %** del residuo estimado.

1. Introducción y motivación del desarrollo

El problema de investigación es cuantificar biomasa residual agrícola (rastrojos y restos de cosecha) a partir de estadísticas oficiales de producción, con resolución espacial suficiente para análisis departamental. Adopté el modelo:

$$BR = P \times FR, \text{ con } FR = (1 - IC) / IC$$

donde P es la producción de grano e IC el índice de cosecha. Esta relación es la vía habitual cuando no se dispone de mediciones directas de residuo a la misma escala (Fan et al., sobre relaciones harvest index–rendimiento para estimar residuo aéreo).

Mi aporte de ingeniería no se limita a aplicar la fórmula: diseñé e implementé el software que **obtiene** los datos, **homogeneiza** nomenclaturas divergentes, **evita doble conteo**, **documenta descartes** y **expone** resultados de forma reproducible. Este informe describe ese proceso de desarrollo, los obstáculos que encontré y las soluciones que implementé.

2. Visión general del sistema que construí

Organicé el código en un paquete Python instalable (`etl`) con extractores, transformadores, loaders y un entrypoint (`etl.pipelines.run_etl`), más un dashboard Streamlit multipágina y orquestación Docker. La arquitectura resultante es la siguiente:

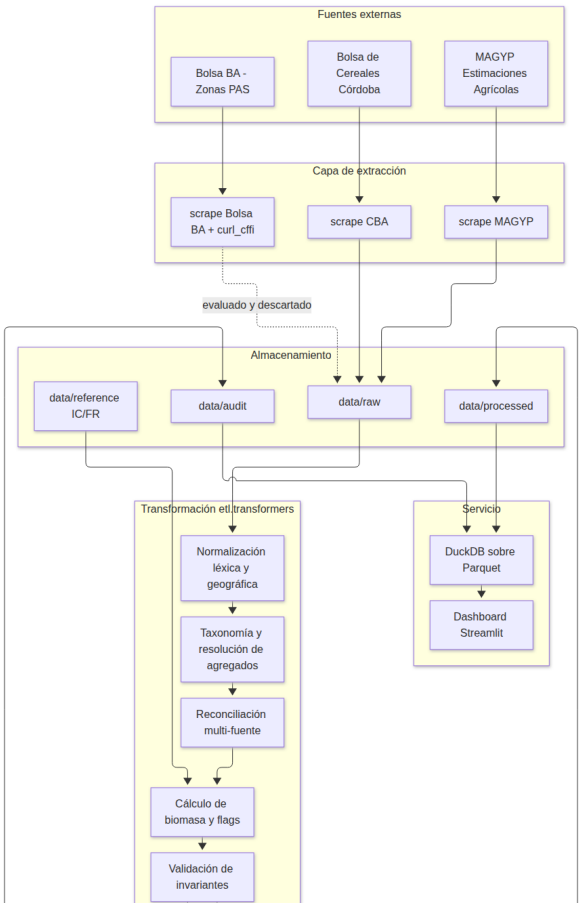


Figura A. Arquitectura del sistema: fuentes, extracción, transformación, almacenamiento y servicio.

3. Extracción de datos: problemas y soluciones

3.1 Portal MAGYP

Implementé un extractor que consulta el portal de Estimaciones Agrícolas: obtiene el período disponible, el catálogo de provincias y departamentos, y luego itera combinaciones provincia–departamento para consolidar superficie sembrada/cosechada, producción y rendimiento. Utilicé `httpx` con reintentos ante códigos 429/5xx, demora entre solicitudes y cabeceras de cliente de navegador. **Problema:** el volumen de llamadas secuenciales es alto. **Solución:** reintentos con *backoff*, rate limit configurable y consolidación en CSV bajo `data/raw/`.

3.2 Bolsa de Cereales de Córdoba

Desarrollé la descarga y normalización de columnas hacia un CSV con provincia, departamento, cultivo, campaña, superficies, rendimientos y producciones. Esta fuente ya discrimina por departamento, por lo que es compatible con MAGYP.

3.3 Bolsa de Cereales de Buenos Aires y Cloudflare

Intenté incorporar la serie nacional de la Bolsa de Cereales de Buenos Aires. El endpoint está protegido de forma que una petición HTTP simple es bloqueada o no devuelve el archivo útil. **Problema destacado:** protección tipo **Cloudflare** (desafíos TLS / huella de cliente). **Solución:** utilicé **curl_cffi** (wrapper de Python sobre curl-impersonate) con `impersonate="chrome110"`, reproduciendo el perfil TLS/HTTP de Chrome. Validé HTTP 200 antes de persistir el Excel.

3.4 Decisión de diseño: exclusión de la serie PAS

Aunque logré descargar la serie de Bolsa BA, **no la integré al modelo departamental**. El dataset usa **zonas PAS** (catorce zonas agroecológicas del Panorama Agrícola Semanal). Varias cruzan provincias o agrupan departamentos distintos. Integrarlas habría exigido desagregación espacial arbitraria, incompatible con la clave natural usada para reconciliar MAGYP y CBA. Conservé el extractor para trazabilidad y análisis eventual a escala PAS fuera del alcance departamental.

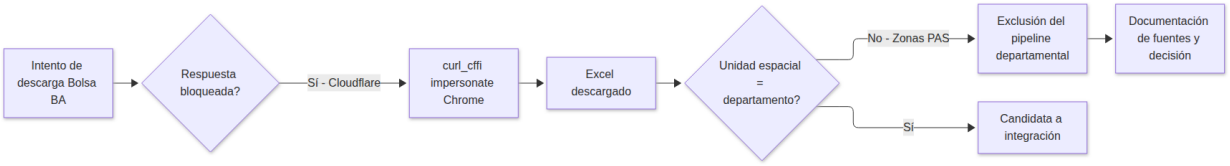


Figura B. Flujo de descarga de Bolsa BA (Cloudflare → curl_cffi) y exclusión por unidades PAS.

4. Transformación: problemas de calidad y código que escribí

Tras inspeccionar las fuentes retenidas, identifiqué problemas de integración y los resolví con módulos bajo `etl.transformers`.

4.1 Hallazgos que motivaron el diseño

Código	Problema observado	Consecuencia si no se trata
H1	MAGYP 23 provincias; CBA 7; intersección parcial	Doble conteo en claves solapadas
H2	Capitalización y espacios distintos en cultivos	Falsos no-matches
H3	Coexistencia de agregados y componentes	Doble conteo interno
H4	Abreviaturas y puntuación en departamentos	Rotura de clave geográfica
H5	Columnas CBA grano limpio/seco ~5 % cobertura	Ruido si se usan como variable principal
H6	Columnas numéricas MAGYP como texto	Imposibilidad de sumar/reconciliar
H7	Solo 17 cultivos con IC en tabla de referencia	Sin coeficiente no hay BR

4.2 Normalización léxica (string_utils)

Implementé una función determinística e idempotente: Unicode NFKD, eliminación de diacríticos, minúsculas y colapso de espacios. Sin este paso el *join* entre fuentes falla por diferencias ortográficas. La normalización previa al *record linkage* es práctica reconocida en resolución de entidades.

4.3 Normalización geográfica (geography)

Pipeline de limpieza de topónimos: normalización léxica, eliminación de puntos, diccionario de abreviaturas y alias, para alinear nomenclatura departamental CBA con MAGYP.

4.4 Taxonomía y agregados (crop_consolidation)

Taxonomía canónica declarativa. POL-CROP-001: si coexisten agregado y componentes, prevalece el agregado; si no hay agregado, se conservan y suman los componentes. No colapso entidades biológicamente distintas (trigo vs trigo candeal).

4.5 Reconciliación multi-fuente (reconciliation)

POL-SOURCE-001: en claves (Provincia, Departamento, Campaña, Cultivo) con más de un registro, retengo el de mayor producción declarada y persisto descartes en auditoría. Regla explícita y auditable en ausencia de *ground truth*.

4.6 Biomasa residual y validez (biomass)

Fusión con tabla IC/FR, BR = P × FR, invalidación de infinitos y flags (`_tiene_ic`, `_valido_biomasa`). Prohibí `dropna` global: el filtro es por flag (POL-MISSING-001).

4.7 Validación (validation)

Chequeos de invariantes post-reconciliación (unicidad de clave, procedencia, no negatividad) antes de persistir.

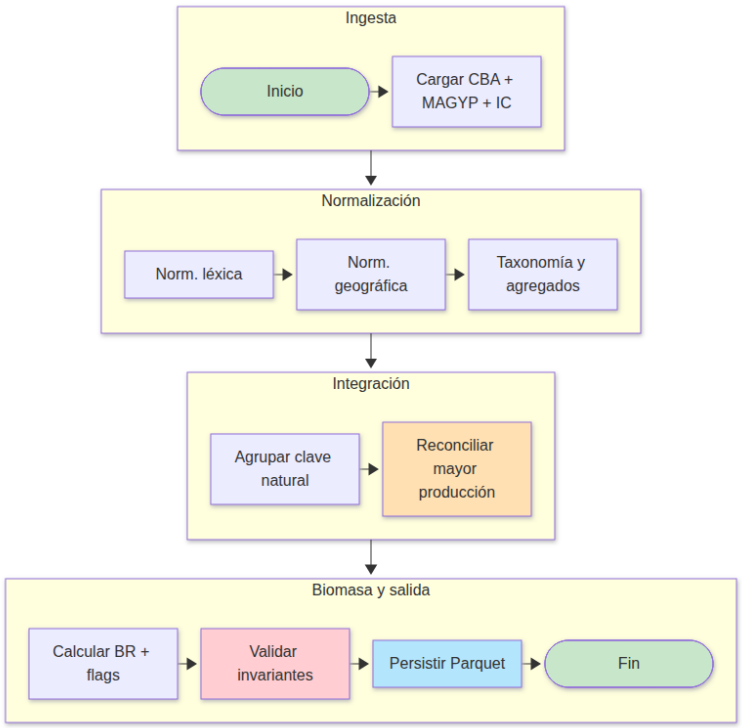


Figura C. Flujo del pipeline ETL (ingesta → normalización → integración → biomasa y salida).

5. Contenerización con Docker: por qué y cómo la usé

Necesitaba reproducibilidad del entorno Python, separación de responsabilidades (pipeline, programación horaria y dashboard), ejecución en Windows y Linux, y zona horaria `America/Argentina/Buenos_Aires`. Construí una imagen única (Dockerfile multi-stage sobre `python:3.11-slim`) e instalé el paquete local para que `import etl.*` sea estable.

Servicio	Rol
etl_worker	Contenedor permanente; el scheduler dispara aquí el ETL; monta data/, config/, logs/
etl_pipeline	Perfil one-shot para corridas manuales
scheduler	Imagen Ofelia; lee config/schedule.ini (cron, p. ej. diario 06:00)
dashboard	Mismo image; Streamlit en puerto 8501; datos en solo lectura

Detalle operativo: en Docker Desktop (Windows) los bind mounts de data/logs a menudo no son escribibles por el usuario no-root; configuré `user: "0:0"` en servicios ETL que escriben artefactos.

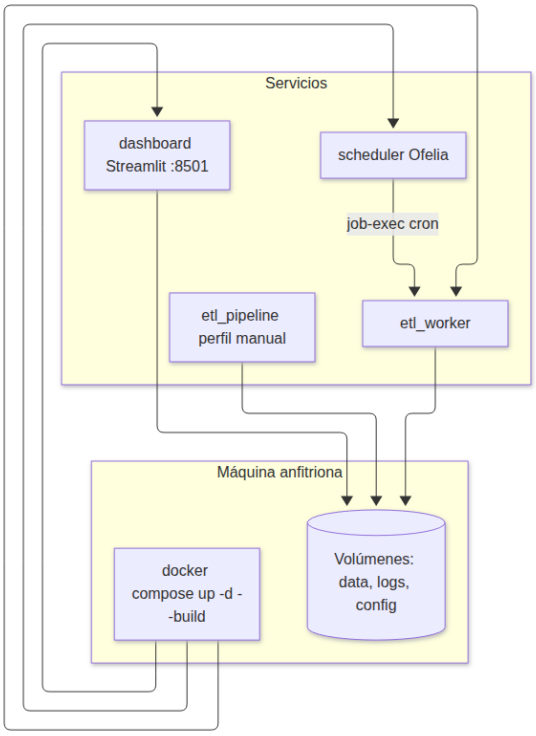


Figura D. Orquestación Docker Compose: worker, scheduler Ofelia, dashboard y volúmenes.

6. Carga, auditoría y visualización

El loader escribe datasets curados y auditoría (discrepancias CBA vs MAGYP, descartados de reconciliación, `biomasa_validos.parquet`). El dashboard Streamlit multipágina (Resumen, Exploración, Auditoría) consulta Parquet vía DuckDB, sin reprocesar el ETL. Incluí geoJSON departamental/provincial para vistas espaciales.

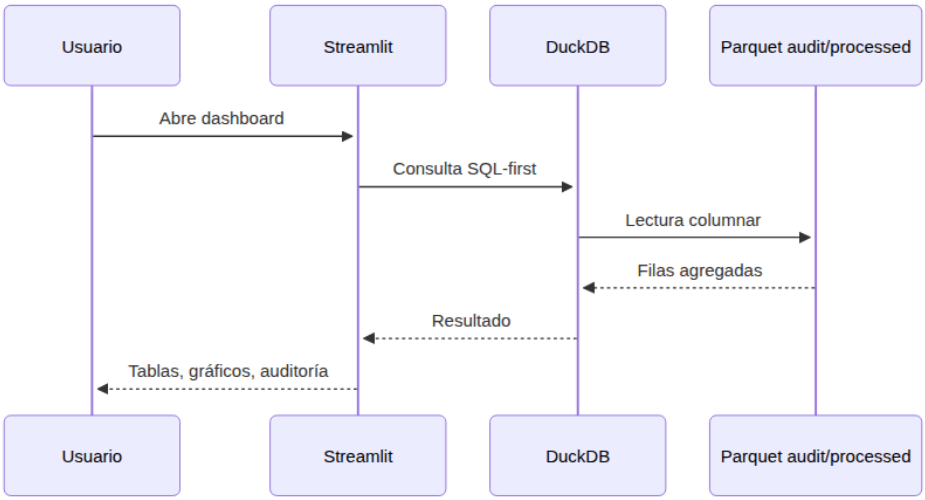


Figura E. Secuencia de consulta del dashboard (Usuario → Streamlit → DuckDB → Parquet).

7. Resultados cuantitativos del pipeline

Criterio	Valor
Registros válidos	121 604 (82,22 %)
Registros no válidos (principalmente sin IC)	26 299 (17,78 %)
Producción retenida	87,59 % del total declarado
Residuo concentrado en válidos	97,53 %
Provincias	23
Departamentos	411

Criterio	Valor
Cultivos canónicos con IC	17

Cultivos excluidos del cálculo de BR por falta de IC: alpiste, arveja, banana, caña de azúcar, cártamo, cebolla, jojoba, lenteja, limón, mandarina, mijo, naranja, pomelo, té, trigo candeal, tung, yerba mate.

7.1 Figuras de resultados empíricos

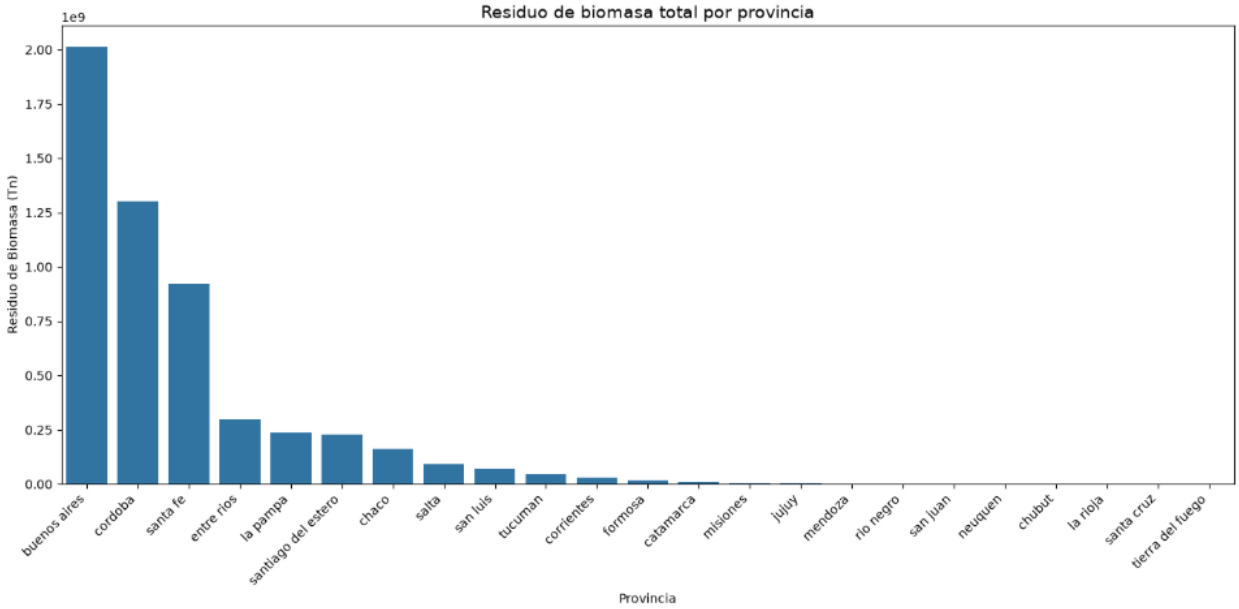


Figura 1. Residuo de biomasa total por provincia.

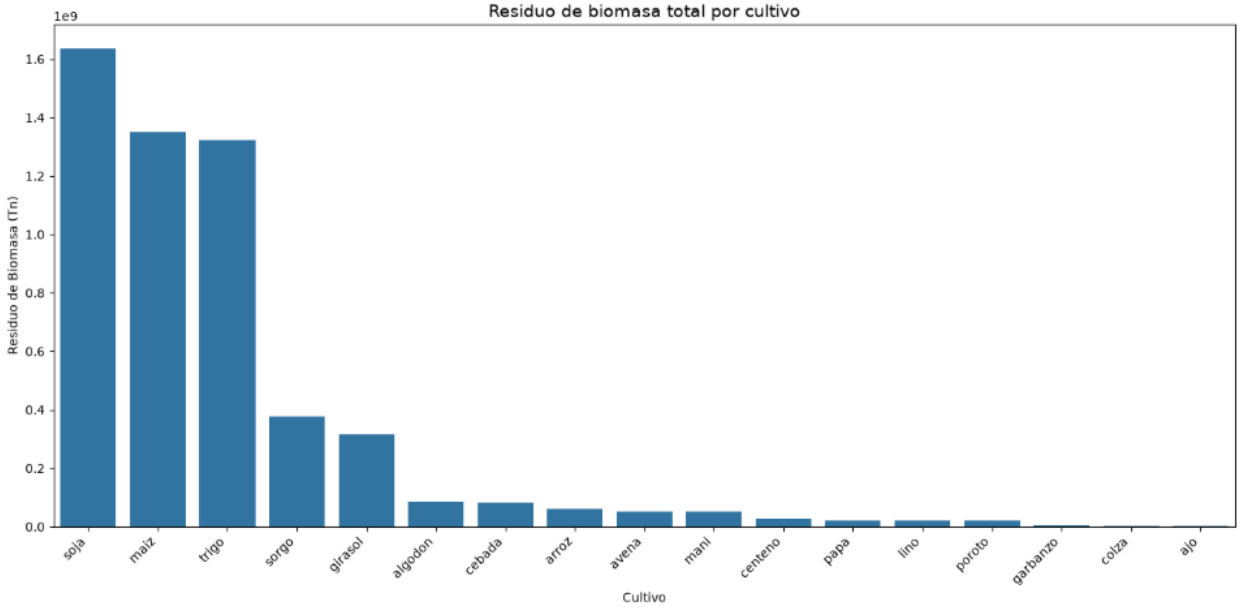


Figura 2. Residuo de biomasa total por cultivo.

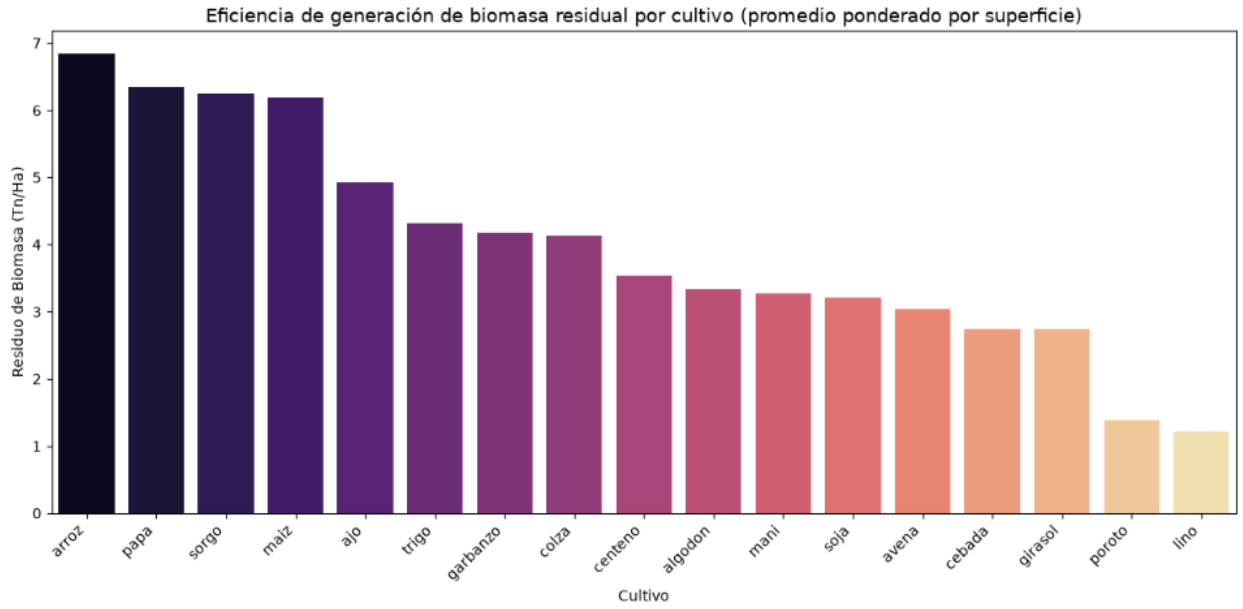


Figura 3. Eficiencia de generación de biomasa residual por cultivo (Tn/Ha, ponderado por superficie).

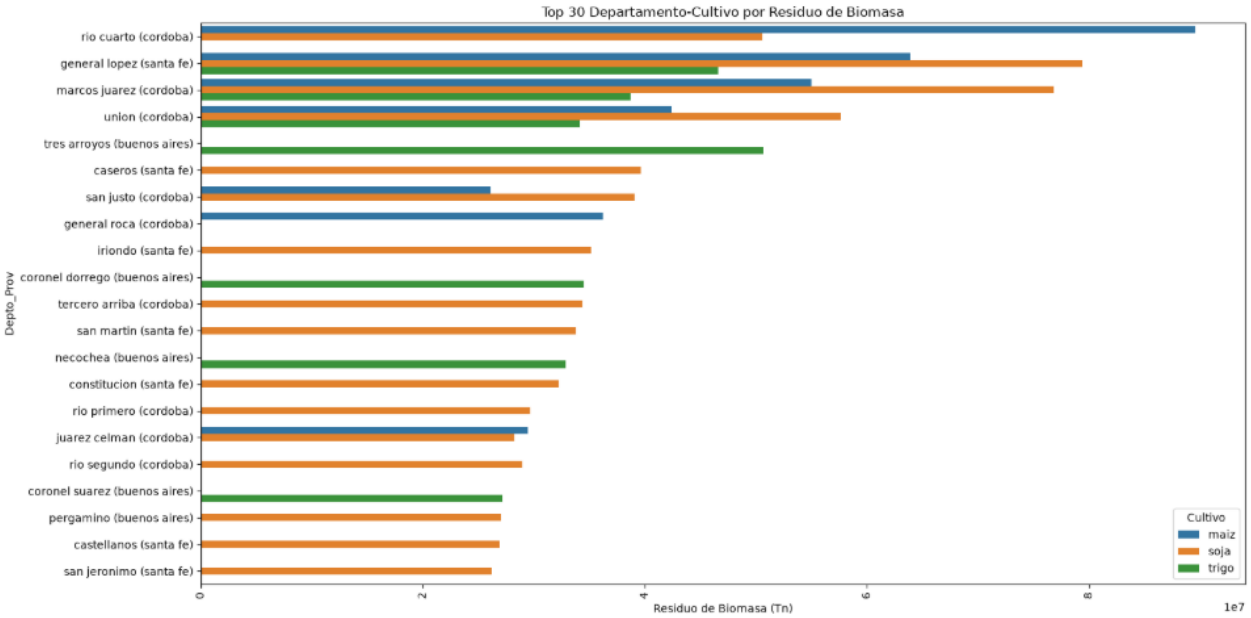


Figura 4. Top 30 combinaciones departamento–cultivo por residuo de biomasa.

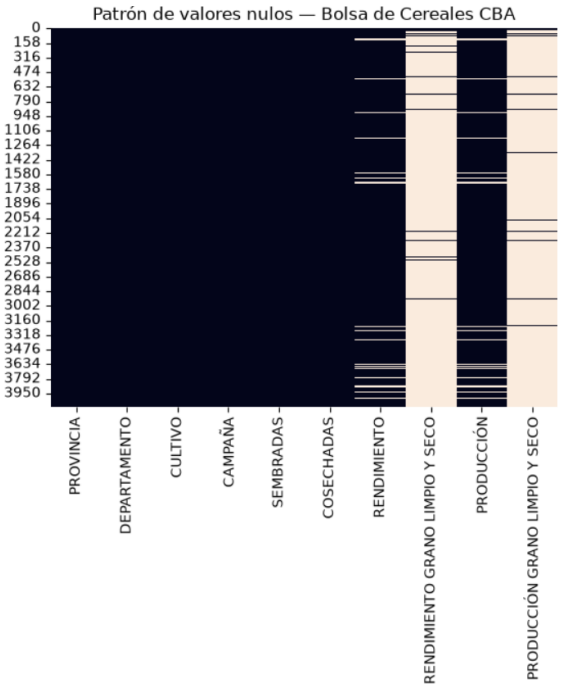


Figura 5. Patrón de valores nulos — Bolsa de Cereales CBA.

8. Limitaciones que asumo explícitamente

1. **IC constante por cultivo**, sin ajuste por rendimiento, genotipo o región.
2. **Subrepresentación posible de NOA/NEA** al excluir cultivos sin IC.
3. **Reconciliación por máxima producción** no validada contra mediciones de campo independientes.
4. **Serie PAS** excluida del modelo departamental pese a haber resuelto su descarga.
5. Este documento es un **informe de avance de tesis**, no un informe oficial institucional ni una publicación arbitrada.

9. Conclusiones del avance

En este tramo de OPTIMIA-HV construí de extremo a extremo el software necesario para estimar biomasa residual departamental a partir de fuentes oficiales compatibles: extractores (incluido el bypass de Cloudflare con `curl_cffi`), transformaciones con políticas documentadas, validación, persistencia auditable, contenedores Docker con programación Ofelia y dashboard Streamlit. El principal conflicto espacial —zonas PAS versus provincia/departamento— lo resolví excluyendo la serie incompatible del modelo. El pipeline queda reproducible y preparado para iterar coeficientes IC, ampliar cobertura de cultivos y profundizar el análisis espacial en etapas posteriores de la tesis.

10. Referencias

Fan, J., McConkey, B., Janzen, H., Townley-Smith, L., & Wang, H. Línea de trabajo sobre relaciones harvest index–rendimiento para estimar residuo aéreo. *Field Crops Research*. https://www.sciencedirect.com/science/article/pii/S0378429016306840

Desarrollos sobre residue-to-product ratio (RPR) y equivalencia RPR = (1–HI)/HI (Scarlat y trabajos posteriores de modelado empírico a escala amplia).

Trabajos de gazetteer matching / resolución de entidades geográficas (record linkage de topónimos entre catálogos).

Lineamientos FAO y documentos técnicos sobre reconciliación de series de censos y encuestas agrícolas ante discrepancias de cobertura o definición.

Fin del informe de avance — OPTIMIA-HV / Marco Ferro / Universidad Nacional de Villa Mercedes.